

Azərbaycan dili üçün ASR sistemi

Müəllif: Ravan Əlizadə · May 2026 · github.com/ravanalizade/az-stt-intern

Giriş

Bu intern tapşırığı open-source Whisper-small (244M parametr) modelindən istifadə edərək Azərbaycan dili üçün avtomatik nitq tanıma (ASR) pipeline-ı qurdum, modelin baseline performansı ölçdüm və LoRA üsulu ilə fine-tune elədim.

2 fərqli dataset işlətdim ümumi 2 fərqli exp oldu(hər ehtimala çünki təklif edilən dataset balaca idi)

- Eksperiment 1 — Mozilla Common Voice 17 (tapşırıqda təklif edilən dataset). Datasetin Azərbaycan dili üçün son dərəcə kiçik olması (cəmi 130 nümunə) səbəbindən fine-tuning baseline nı aşmadı.
- Eksperiment 2 — Google FLEURS (alternativ dataset). Daha böyükdür (4000 nümunə) və ona görə fine-tuning kiçik amma real yaxşılaşma verdi.

Yekun nəticələr:

Eksperiment	Dataset	Test ölçüsü	Baseline WER	Fine-tuned WER	Δ
1	Common Voice 17	33	62.16%	62.55%	+0.39 pp
2	FLEURS	923	52.76%	52.47%	-0.29 pp

Eksperiment 1: Common Voice 17

Hissə A: Baseline

Metrik	Dəyər
Test nümunə sayı	33
WER	62.16%
CER	17.42%
Real-time factor (T4 GPU)	0.05

WER və CER arasındakı böyük fərq (təxminən 3.5 dəfə) əhəmiyyətlidir: model səsləri düzgün eşidir, lakin Azərbaycan dilinə xas hərfləri (ə, ş, ğ, ı, ö, ü) düzgün yazmır. Aşağıdakı nümunədə bunu görmək olar:

REF: "Kanalda İngilis və İspan dillərdə proqramlar nümayiş olunur."

HYP: "Kanalda, İngiliz və İspandillərdə proqramlar nümayiş olunur."

Burada İngilis → İngiliz, nümayiş → nümayış kimi xırda hərf dəyişiklikləri olur — fonetik baxımdan oxşar, lakin orfoqrafik baxımdan səhv.

Hissə B: Fine-tuning

Common Voice 17-də Azərbaycan dili üçün cəmi 130 audio mövcuddur (65 train, 32 dev, 33 test). 65 nümunə LoRA fine-tuning üçün son dərəcə azdır.

Konfigurasiya: LoRA ($r=32$, q_proj+v_proj), AdamW, $lr=5e-5$, 10 epox, batch=8.

Model	WER	CER
Baseline (Whisper-small)	62.16%	17.42%
Fine-tuned (LoRA, 65 nümunə)	62.55%	17.69%
Δ	+0.39 pp	+0.27 pp

Traning grafikləri (results/training_curves.png) klassik overfitting göstərir: validation WER 1-ci epoxdan sonra minimumdadır, sonra yüksəlir. `load_best_model_at_end` avtomatik olaraq 1-ci epox checkpoint-ini seçdi, lakin bu checkpoint belə baseline ni aşmadı.

Nəticə: pipeline texniki cəhətdən düzgündür, lakin 65 təlim nümunəsi multilingual pretrain edilmiş modeli yaxşılaşdırmaq üçün yetərli deyil. Bu, Common Voice Azərbaycan dili üçün az həcmnin olmasının nəticəsidir.

Eksperiment 2: FLEURS

Common Voice nəticələrindən sonra alternativ dataset axtardım. Google FLEURS (az_az config) Azərbaycan dili üçün 2665 train, 400 dev, 923 test nümunəsi (təxminən 10 saat audio) təqdim edir — Common Voice-dan ~30 dəfə çox.

Tapşırıq spesifikasiyasında "Bu dataseti istifadə etməyə məcbur deyilsiniz" qeyd edildiyi üçün FLEURS ilə ikinci eksperiment aparıldı.

Hissə A: FLEURS baseline

Whisper-small-un—FLEURS Azərbaycan test seti (923 nümunə) üzrə performansı:

- WER: 52.76%
- CER: 14.86%
- Real-time factor: 0.04

FLEURS baseline Common Voice-dan ~10 pp daha aşağıdır. Səbəbləri:

- FLEURS audiosu daha təmizdir (oxuma nitqi, professional yazma vs Common Voice-un volunteer telefon yazıları)
- 923 nümunə statistik baxımdan 33 nümunədən qat-qat etibarlıdır

Hissə B: FLEURS fine-tuning

Common Voice təcrübəsindən öyrəndiklərimiz:

- Yüksək LR pretrain edilmiş modelin öyrənməyin pozur — Common Voice-da $lr=1e-4$ və $5e-5$ hər ikisi pisləşdi
- Çox epox subsetə overfit edir
- LoRA + gradient_checkpointing kombinasiyası `model.enable_input_require_grads()` tələb edir
- fp16 mixed precision NaN gradientlərə səbəb olur — fp32 daha sabitdir

FLEURS üçün config:

- Model: openai/whisper-small
- Üsul: LoRA ($r=32$, $\alpha=64$), q_proj və v_proj
- Treyn olunan parametrlər: 3,538,944 / 245,273,856 (1.44%)
- Optimizator: AdamW, $lr=5e-6$ (LoRA üçün adi $1e-4$ -dən $20\times$ kiçik)
- Epox sayı: 2 (subtle adaptasiya üçün kifayət)
- Batch: 8, gradient accumulation 2 (effektiv 16)
- Treyn: 500, validasiya: 100 nümunə

Nəticələr (923-nümunəli test set):

Model	WER	CER
baseline (Whisper-small)	52.76%	14.86%
Fine-tuned (LoRA, $lr=5e-6$, 2 epox)	52.47%	14.65%
Δ	-0.29 pp	-0.21 pp

WER 52.76% $\rightarrow$ 52.47% (-0.29 pp), CER 14.86% $\rightarrow$ 14.65% (-0.21 pp). Hər iki metrik üzrə kiçik amma yaxşılaşma.

Yüksək LR ilə müqayisə

FLEURS-un eyni datasetdə $lr=5e-5$ (LoRA üçün adi qiymət) ilə də fine-tuning aparıldı. Nəticə: WER 52.76% $\rightarrow$ 55.30% (+2.54 pp), pisləşmə.

Hissə C: Təhlil

C1. Çətinliklər və həllər

1. Datasetin əldə edilməsi

Mozilla 2025-ci ilin oktyabrında Common Voice datasetinin Hugging Face mirror-unu deaktiv etdi və Mozilla Data Collective-ə keçdi. mozilla-foundation/common_voice_17_0 artıq boşdur. Həll yolu kimi fsicoli/common_voice_17_0 icma mirror-undan istifadə etdim.

İkinci problem: datasets ≥ 3.0 versiyaları "loading script" formatını dəstəkləmir. Hər iki dataset (fsicoli/common_voice_17_0 və google/fleurs) bu formatı istifadə edir. Həll yolu kimi tar arxivlərini və TSV transkriptlərini birbaşa urlib ilə endirib özüm parse etdim. Bu yanaşma üçüncü tərəf API dəyişikliklərindən asılı deyil.

2. Məhdud verilənlər

Common Voice 17-də Azərbaycan dili üçün cəmi 130 audio kliplər mövcuddur. Bu rəqəm 244M parametrlili multilingual modelin fine-tune edilməsi üçün son dərəcə azdır. Müqayisə üçün:

- İngilis dili üçün CV 17-də təxminən 3.6 milyon klip
- Türk dili üçün təxminən 80,000 klip

- Whisper paper-i Azərbaycan dili üçün təlim zamanı təxminən 3 saat audio istifadə etdiyini bildirir

FLEURS daha yaxşı seçimdir (~4000 nümunə), lakin yenə də ingilis dili üçün olan datasetlərdən kiçikdir.

3. Whisper + LoRA texniki problemləri

- fp16 + gradient checkpointing: NaN gradientlərə səbəb olur. Həll: fp32-ə keçid.
- LoRA + gradient checkpointing encoder input-ları gradient propaqasiya etmir. Həll: `model.enable_input_require_grads()` çağırışı.
- `forced_decoder_ids` münaqişəsi: model konfiqurasiyasında və generation config-də eyni vaxtda olduqda, evaluation zamanı dil aşkarlanmasına qayıdır. Həll: `model.generation_config.language = "azerbaijani"` təyin etmək və `forced_decoder_ids = None` etmək.

4. Learning rate seçimi

LoRA üçün adi olan $1e-4$ və $5e-5$ LR-lər artıq yaxşı pretrain edilmiş modeli pozur. Yalnız çox aşağı LR ($5e-6$) ilə yaxşılaşma əldə edildi. Bu, low-resource scenario-da "gentle adaptation" yanaşmasının vacibliyini göstərir.

C2. Xəta analizi

Modelin etdiyi xətlər 4 əsas kateqoriyaya ayrılır:

Əsas səhvlər

- Azərbaycan → Azerbaycan (ə → e)
- nümayiş → nümayış (i → ı)
- gözəldir → gozeldir (ö → o)

Bu xətlər CER-i çox az artırır, lakin WER-i kəskin yüksəldir, çünki bütöv söz "səhv" hesab olunur.

Xüsusi adların yanlış tanınması

- Komsomol gölü → Qab-Sumul gölü (yer adı)
- Qrup → Grup (Azərbaycan latın əlifbasında "Q" hərfi)

Qısa kliplərdə hallüsinasiya

- Cənubi Koreyada → Canubi, Corea da (3.3s klipdə kontekst azlığı)
- İyunun əvvəlində → Yəni, nəvvəlində

Sözlərin parçalanması/birləşdirilməsi

- İspan dillərdə → İspandillərdə (boşluq itib)
- birlikdə → birlik də (boşluq əlavə olunub)
-

C3. Yaxşılaşdırma təklifləri

Texniki səviyyədə:

- Beam search: hazırda num_beams=1 istifadə olunur. Beam search WER-i 1-2 pp azalda bilər.
- Whisper-medium və ya Whisper-large: daha böyük modellər Azərbaycan dilini daha yaxşı tanıyır, lakin daha çox VRAM tələb edir.
- Daha çox FLEURS təlim nümunəsi: 500 yerinə bütün 2665 təlim nümunəsindən istifadə daha böyük yaxşılaşma verə bilər.

Data səviyyəsində

- Self-supervised pretraining: YouTube, podcast, radio mənbələrindən etiketlenməmiş Azərbaycan səsinə istifadə edərək Whisper encoder-ini əlavə pretrain etmək.
- Sintetik məlumat artırılması: yüksək keyfiyyətli Azərbaycan TTS modeli ilə sintetik audio yaratmaq.
- Krowdsourcing kampaniyası: Common Voice-a qatqı təşviqi.

Production üçün:

- VAD (Voice Activity Detection): səssizlik və fon səsinə hallüsinasiyaları azaltmaq üçün.
- Language model rescoreing: Whisper output-unu Azərbaycan dilində training edilmiş LM ilə yenidən sıralamaq.
- Domain adaptation: spesifik domenlər üçün (tibb, hüquq, çağrı mərkəzi) əlavə fine-tuning.

Yekun mülahizələr

Əsas töhfələri:

- Düzgün ASR pipeline-i: data loading, inference, evaluation, fine-tuning, müqayisə
- İki dataset üzərində reproducible nəticələr (Common Voice və FLEURS)
- Real engineering judgment: birinci yanaşma uğursuz olduqda alternativ axtarmaq və tapmaq
- Low-resource fine-tuning üçün konkret texniki dərslər (LR seçimi, epox sayı, fp16 problemləri)

Mənfi nəticə də (Common Voice fine-tuning) məlumatlandırıcıdır: pipeline işləyir, problem datasetin ölçüsündədir. FLEURS ilə kiçik amma real yaxşılaşma göstərdi ki, düzgün konfigurasiya ilə pretrain edilmiş model üzərində adaptasiya mümkündür.

Azərbaycan ASR üçün ən böyük problem nədir?

Açıq mənbəli, müxtəlif domenləri və danışanları əhatə edən, label edilmiş genişmiqyaslı səs datasetlərinin və databasaların olmamasıdır.